

# Transcriptome analysis using RNA-Seq

유전체 빅데이터 분석 예비 전문가 과정 실무 프로젝트 리포트

8기 이 택 규

2020.09.02 ~ 04

#### **Reference Information**

- 종 : Arabidopsis thaliana

- 데이터베이스: Ensembl (release 44)

- Genome size : ~ 135 Mbp

- Gene model

- No. All genes : 32833 (제공된 GTF 기준)

- No. Masked genes : 5205 (제공된 GTF 기준)



#### **RNA-Seq Information**

Tissue	Treatment	Time point	Sample Name	No. Raw Reads
Shoot	Control	6h	Shoot-Control-6h	8135267
Shoot	Control	12h	Shoot-Control-12h	7387742
Shoot	Control	24h	Shoot-Control-24h	7443630
Shoot	PA01	6h	Shoot-PA01-6h	7245643
Shoot	PA01	12h	Shoot-PA01-12h	7763482
Shoot	PA01	24h	Shoot-PA01-24h	7213743

• Inner distance : 250 bp (standard deviation : 50 bp)

• Library type : fr-unstranded

• Library Prep Kit: TruSeq stranded mRNA Library Prep kit

TruSeg Universal Adapter: 5 AATGATACGGCGACCACCGAGATCTACACTCTTTCCCTACACGACGCTCTTCCGATCT 3

\* TruSeq Indexed Adapter: 5 GATCGGAAGAGCACACGTCTGAACTCCAGTCAC-NNNNNN-ATCTCGTATGCCGTCTTCTGCTTG 3

### Sample Info.

#### About Arabidopsis thaliana (PRJNA361001)

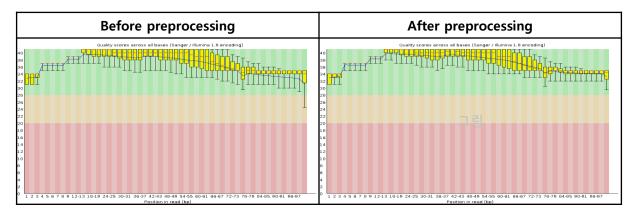
Arabidopsis thaliana is a small flowering plant that is widely used as a model organism in plant biology. Arabidopsis is a member of the mustard (Brassicaceae) family, which includes cultivated species such as cabbage and radish. Arabidopsis is not of major agronomic significance, but it offers important advantages for basic research in genetics and molecular biology. Arabidopsis thaliana has a genome size of ~135 Mbp, and a haploid chromosome number of 5.

#### Reads count & Expressed gene count Table

	Rea	d Preprocessi	ng	Reference mapping (Alignment) Expressed Genes		
Sample Name	Raw Reads	Clean Reads	Rate, % (per Raw)	Mapped Reads	Rate, % (per Clean)	RPKM >= 0.3
Shoot-Control-6h	8135267	7770134	95.51	7622651	97.8	19151
Shoot-Control-12h	7387742	7068967	95.69	6922417	97.7	19122
Shoot-Control-24h	7443630	7117908	95.62	6985858	98.0	19218
Shoot-PA01-6h	7245643	6917874	95.48	6783048	97.9	19398
Shoot-PA01-12h	7763482	7439003	95.82	7295714	97.9	19518
Shoot-PA01-24h	7213743	6901930	95.68	6765528	97.9	19645

- Raw Reads를 cutadapt 실행. TruSeq Universal Adapter, TruSeq Indexed Adapter 를 제거.
- 이후, SLIDINGWINDOW size는 4bp, average quality는 20, MINLEN은 50bp로 설정하여 trimming을 진행.
- Library type이 fr-unstranded이기 때문에, Expressed Genes이 RPKM >= 0.3 인 것들을 in vivo 상에서 발현하고있다고 정의.
- Align 정보와 trimming정보는 추가 page에 기재.(Fig.01)

#### Per base sequence quality (Shoot-Control-6h R1)



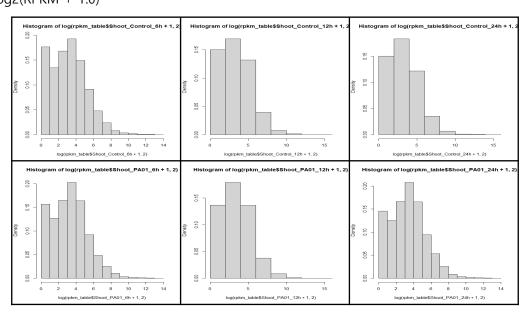
- trimming 후 Shoot-Control-6h R1 에대한 quality 정보.
- 서열 끝부분에서 base quality 의 변화.
- GC contents는 추가 page에 기재.(Fig.02)

#### **Expressed Gene Selection**

- No. Total genes: 32823 (cuffnorm 결과 기준)
- No. Selected genes : 20863 (적어도 한 샘플에서라도 RPKM >= 0.3 인 유전자만 선택)

#### Histogram

Input genes : Selected genesValue : log2(RPKM + 1.0)

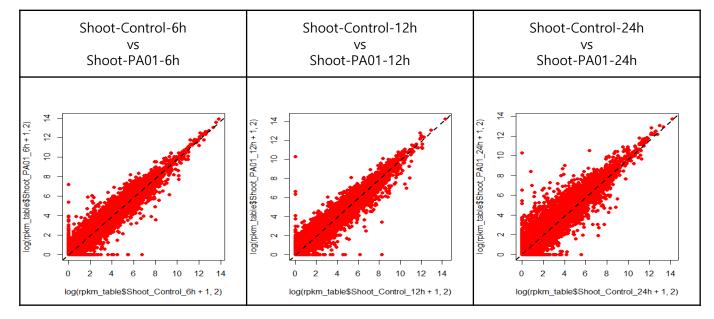


- 각 sample에서 발현량을 확인하기위한 histogram.
- 각 sample에서 RPKM >= 0.3 인 gene을 채택.
- 각 sample에서 발현량 확인.
- density 정보는 추가 page에 기재.(Fig.03)
- Control, Experimnet 의6h와 12h sample 에서 발현량이 비슷한 양상을 가지고있음.
- 24h sample에서는 발현량의 양상에서 차이 발생.
- PA01처리 이후 24h 에서 발현량의 차이 발생.

#### Scatter plot

- Input genes : Selected genes

- Value : log2(RPKM + 1.0)

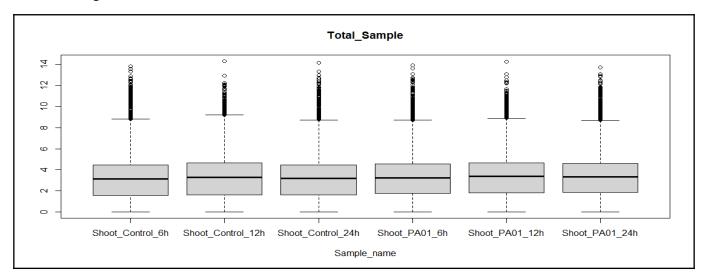


- 동일 시간에서 sample간 scatter plot의 결과.
- RPKM >= 0.3 인 gene을 채택.
- sample간 발현양상을 대략적으로 확인가능.
- 6h sample 간 비교시, 발현량의 차이가 있지만, 발현 양상이 유사하기 때문에 얇게(narrow)하게 분포하는 양상을 가짐.
- 12h sample간 비교시, 6h sample과는 약간의 차이 존재, 발현 양상이 유사하지 않은 gene이 약간 증가.
- 24h sampl간 비교시, 발현량의 차이가 6h,12h sample과는 달리 분포가 넓게(wide)하게 나타남.
- 결론적으로 scatter plot만 분석해보았을때, 각 gene의 발현이 6h,12h에는 많은 차이가 존재하지 않는 다는 것을 확인. 하지만 24h에서는 발현량이 달라졌다는 것을 대력적으로 확인가능.
- 동일 group 다른 시간대 추가 분석자료 추가 page기재.(Fig.04)

#### **Box plot**

- Input genes : Selected genes

- Value : log2(RPKM + 1.0)



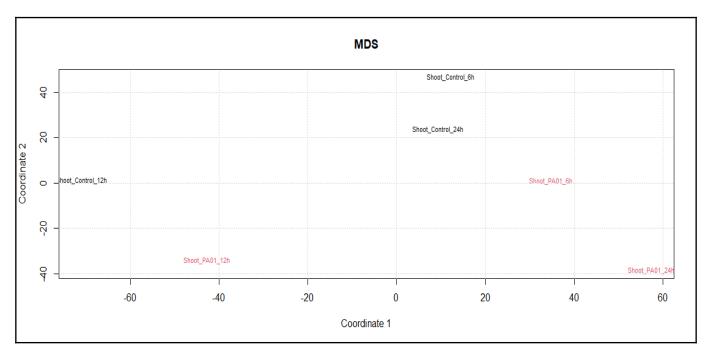
- boxplot으로 전체 sample에 대한 시각화.
- RPKM >= 0.3 인 gene을 채택.

#### **MDS**

- Input genes : Selected genes

- Value : log2(RPKM + 1.0)

- Method for distance calculation: "euclidean"



- MDS로 전체 sample에 대한 시각화.
- RPKM >= 0.3 인 gene을 채택.
- Euclidean distanc를 통해 거리 계산.
- MDS결과를 통해, 각 sample간의 거리 확인.
- Control과 Experiment group에서 group안의 sample의 위치를 확인한 결과, 공통적으로 group 안에서 12h sample의 거리가 다른 두 sample 보다 먼 것을 확인.
- 이를 통해 12h에서 발현양의 차이 유추가능.

#### **DEG Selection**

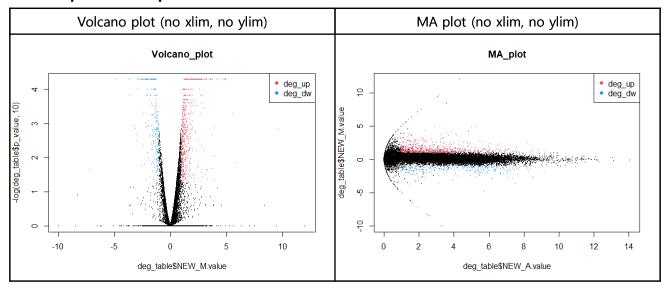
- No. Total genes : 32823 (Cuffdiff 결과 기준)

Average New A-value : 2.1(2.115738) (소수점 2자리에서 반올림)Average New M-value : 0.1(0.1102173) (소수점 2자리에서 반올림)

- No. Selected DEG: 876

Up regulated DEG: 628Down regulated DEG: 248

#### Volcano plot & MA plot - Cuffdiff



- Cuffdiff의 결과인 DEG에 대한 Volcano plot & MA plot.
- log2(value\_2+0.1) log2(value\_1+0.1)을 통해 New M-value 계산.
- 1/2(log2(value\_2+1)+log2(value\_1+1))을 통해 NEW A-value 계산.
- DEG selection은 abs(New log2(FC))>=1 & p=value < 0.05.
- DEG selection후, Control대비 case에서 up regulate 된 DEG는 628개.
- DEG selection후, Control대비 case에서 down regulate 된 DEG는 248개.
- TCC결과 추가 page기재.(Fig.05)

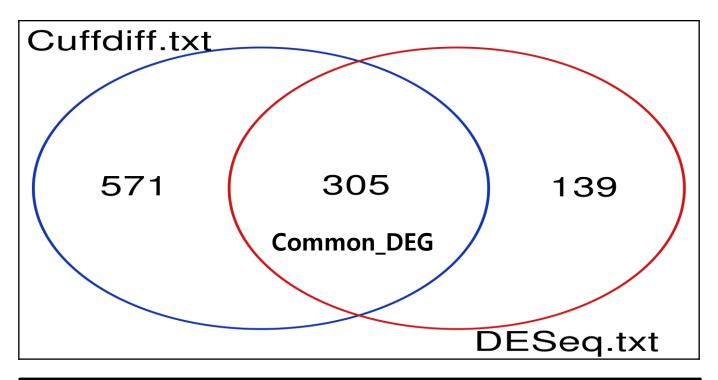
#### **Common DEG**

- No. Selected DEG from Cuffdiff: 876

- No. Selected DEG from TCC: 444

#### Venn diagram

참고: http://bioinformatics.psb.ugent.be/webtools/Venn



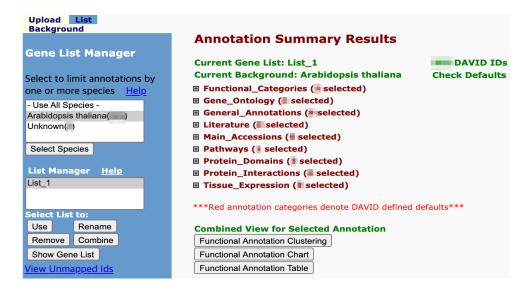
- DEG가 서로 다르게 선별됨.
- 따라서 서로 다른 방법으로 선별된 DEG중에서 Common DEG를 선별하여 사용해야함.
- Common DEG에 대한 정보 추가 page 기재.(Fig06)
- 추가적인 Common DEG 선별위해 edgeR 사용. 추가 page 기재(Fig.07)

#### **DAVID (Optional)**

#### 참고: https://david.ncifcrf.gov/summary.jsp

- Input genes : Common DEG



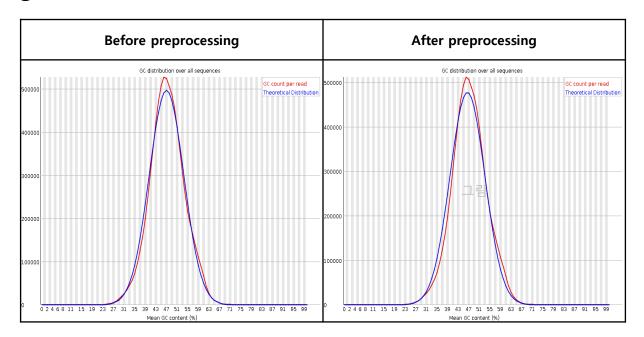




- Arabidopsis thaliana의 Shoot tissu를 각각 6h,12h,24h 로 Control group과 Experiment(PA01) group으로 나누었다. 분석에 필요한 data는 Ensembl data를 사용하였다. 분석은 rawdata로부터 quality trimmin과정을 거쳐 quantification mode로 분석을 진행하였다. 그리고 HTSeq-count에서 TCC를 deseq으로 진행하였다.
- 결과는 Cuffnorm의 결과로 생성된 genes.fpkm\_table을 사용하여 발현량을 통해 비교하였다. 각 sample에 대한 발현량 확인은 histogram, sample간 발현량 비교는 scatter plot, 전체 sample의 대략적 인 발현량 정보는 boxplot과 MDS를 통해 확인하였다. control group과 experiment group간의 비교를 확인하기 위하여 scatter plot을 통해 결과를 관찰 하였다. 우선 동일 시간끼리 비교한 결과를 통해서는, Shoot-Control-24h와 Shoot-PA01-24h에서 발현양의 차이가 보였다. 하지만 MDS로 판단했을 경우에 는, Shoot-control-12h와 Shoot-PA01-12h가 각 group에서 거리가 가장 멀리 떨어져 있는 것으로 확인 되었다. 따라서 결과 해석이 모호 하므로, Shoot-control-12h와 Shoot-PA01-12h를 group내에서 다른 sample들과 비교하여 추가적인 분석을 진행하였다. 추가 분석은 Control과 Experiment group내에서 Shoot-Control-12h와 Shoot-Control-6h , Shoot-Control-12h와 , Shoot-Control-24h를 비교하였고, Shoot-PA01-12h와 Shoot-PA01-6h, Shoot-PA01-12h와 Shoot-PA01-24h를 비교하였다. 또한 추가적으 로 Shoot-Control-6h와 Shoot-Control-24h를 비교하였고 Shoot-PA01-6h와 Shoot-PA01-24h를 비교 하였다. 결과적으로 각 group에서 12h sample의 발현량이 다른 sample과 차이가 남을 대략적으로 확 인하였으며, MDS분석 결과를 증명하였다. 발현량의 변화가 특정 gene의 발현 유무에 따라 변했다는 것을 확인하기 위해 DEG(diffentially expressed gene)을 확인하였다. Cuffdiff를 통해 나온 결과로 DEG selectio을 진행하였고, New A-value와 New M-value를 통하여 발현되고 있는 DEG가 Control대비 experiment group에서 얼마정도 up regulate되는지, 혹은 down regulate 되고 있는지 확인해보았다. 분석 결과로 총 876개의 DEG중 628개의 DEG가 experiment상에서 up regulate되고 있있고, 248개의 DEG가 experiment상에서 down regulate되고 있음을 확인하였다. 결과적으로 발현량의 차이가 DEG 조절에 의해 나타났다고 말할 수 있다. 하지만 deseq으로 분석한 결과 DEG는 444개로 Cuffdiff의 결과 와 차이가 있었다. 추가 분석 결과로 총 444개의 DEG중 204개의 DEG가 experimen상에서 up regulate되고 있있고, 240개의 DEG가 experimen상에서 down regulate되고 있음을 확인하였다. 따라 서 여러가지 분석 방법을 이용해 공통되는 DEG를 발견하고, 발견한 DEG를 대상으로 sample내에서 common DEG가 발현이 되는지 안되는지, 추가적인 분석을 통해서 확인을 해 보아야 한다. 또한 scatter plot 추가분석 결과를 통해 발현량의 차이가 PA01처리 후 나타난다 라고 단정 짓기가 제한된다 라고 할 수 있다. 이유는 같은 group에서 시간의 차이에 따라 발현량의 차이를 보였음으로, 발현량의 차이가 진정 다른 조건을 가진 group사이에서 발현되는 DEG의 차이인지, 아니면 같은 group내에서 시 간에 따른 변화인지 확실하지 않기때문이다.
- 본 분석에서 Control group과 Experiment group간의 차이를 RPKM값과 DEG를 통해 확인하였다. 분석 결과로 발현량과 DEG의 차이가 나타남을 확인하였으나, 이번 실험에서 정말로 약물처리에 의해서 나타난 결과인지 확신하기는 제한된다. 분석을 통해 약물이라는 조건 외에 발현량에 영향을 미치는 요인을 확인 했기 때문이다. 따라서 추가적인 분석시, 약물외 다른 조건을 명확하게 규명한 상태에서 분석을 진행한다면, 약물처리와 DEG,발현량의 관계를 좀더 깊게 알 수 있을 것이다.

	Trimming Info	
Shoot-Control-6h	Shoot-Control-12h	Shoot-Control-24h
Input Read Pairs: 8135267 Both Surviving Reads: 7770134 Both Surviving Read Percent: 95.51 Forward Only Surviving Reads: 155803 Forward Only Surviving Read Percent: 1.92 Reverse Only Surviving Reads: 148125 Reverse Only Surviving Read Percent: 1.82 Dropped Reads: 61205 Dropped Read Percent: 0.75	Reverse Only Surviving Reads: 126159	Input Read Pairs: 7443630 Both Surviving Reads: 7117908 Both Surviving Read Percent: 95.62 Forward Only Surviving Reads: 141664 Forward Only Surviving Read Percent: 1.90 Reverse Only Surviving Reads: 129002 Reverse Only Surviving Read Percent: 1.73 Dropped Reads: 55056 Dropped Read Percent: 0.74
Shoot-PA01-6h	Shoot-PA01-12h	Shoot-PA01-24h
Input Read Pairs: 7245643 Both Surviving Reads: 6917874 Both Surviving Read Percent: 95.48 Forward Only Surviving Reads: 145991 Forward Only Surviving Read Percent: 2.01 Reverse Only Surviving Reads: 128037 Reverse Only Surviving Read Percent: 1.77 Dropped Reads: 53741 Dropped Read Percent: 0.74	Input Read Pairs: 7763482 Both Surviving Reads: 7439003 Both Surviving Read Percent: 95.82 Forward Only Surviving Reads: 140077 Forward Only Surviving Read Percent: 1.80 Reverse Only Surviving Reads: 128388 Reverse Only Surviving Read Percent: 1.65 Dropped Reads: 56014 Dropped Read Percent: 0.72	Input Read Pairs: 7213743  Both Surviving Reads: 6901930  Both Surviving Read Percent: 95.68  Forward Only Surviving Reads: 126924  Forward Only Surviving Read Percent: 1.76  Reverse Only Surviving Reads: 134237  Reverse Only Surviving Read Percent: 1.86  Dropped Reads: 50652  Dropped Read Percent: 0.70

Align Info		
Shoot-Control-6h	Shoot-Control-12h	Shoot-Control-24h
Left reads:  Input : 7770134  Mapped : 7683225 (98.9% of input) of these: 184736 (2.4%) have multiple alignments (32 have >20)  Right reads: Input : 7770134  Mapped : 7678096 (98.8% of input) of these: 184565 (2.4%) have multiple alignments (32 have >20)  88.8% overall read mapping rate.  Aligned pairs: 7622651 of these: 183142 (2.4%) have multiple alignments 23965 (0.3%) are discordant alignments 7.8% concordant pair alignment rate.	Left reads:	Left reads:  Input : 7117908 Mapped : 7039360 (98.9% of input) of these: 124240 (1.8%) have multiple alignments (25 have >20)  Right reads: Input : 7117908 Mapped : 7036821 (98.9% of input) of these: 124125 (1.8%) have multiple alignments (27 have >20)  98.9% overall read mapping rate.  Aligned pairs: 6885858 of these: 123165 (1.8%) have multiple alignments 9886 (0.1%) have multiple alignments 9886 (0.1%) have multiple alignments
Shoot-PA01-6h	Shoot-PA01-12h	Shoot-PA01-24h
Left reads:  Input : 6917874 Mapped : 6837226 (98.8% of input) of these: 116887 (1.7%) have multiple alignments (29 have >20)  Right reads: Input : 6917874 Mapped : 6832838 (98.8% of input) of these: 11672 (1.7%) have multiple alignments (28 have >20)  38.8% overall read mapping rate.	### reads:  Input: 7439003  Mapped: 7354145 (98.9% of input) of these: 117982 (1.6%) have multiple alignments (67 have >20)  Right reads:  Input: 7439003  Mapped: 7350113 (98.8% of input) of these: 117981 (1.6%) have multiple alignments (69 have >20)  8.8% overall read mapping rate.	Left reads:       Input     : 6901930       Mapped     : 6818424 (98.8% of input)       of these:     98818 (1.4%) have multiple alignments (32 have >20)       Right reads:     Input       Input     : 6901930       Mapped     : 6814215 (98.7% of input)       of these:     98752 (1.4%) have multiple alignments (33 have >20)       18.8% overall read mapping rate.
Aligned pairs: 678304B of these: 115823 (1.7% have multiple alignments 13420 (0.2% are discordant alignments 97.9% concordant pair alignment rate.	ligned pairs: 7295714 of these: 116965 (1.6%) have multiple alignments 10962 (0.2%) are discordant alignments 7.9% concordant pair alignment rate.	Rligned pairs: 6765528 of these: 97843 (1.4% have multiple alignments 11583 (0.2% are discordant alignments 7.9% concordant pair alignment rate.

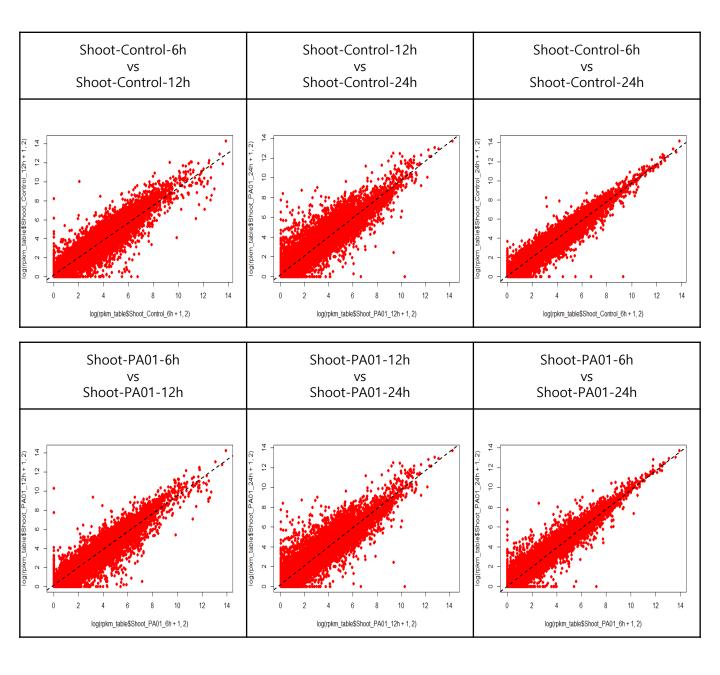


GC contents를 통해 contamination 되지 않은 것을 확인.

## Fig.03

Histogram-count, density		
Shoot-Control-6h	Shoot-Control-12h	Shoot-Control-24h
Scounts [1] 3686 2806 3508 4019 3111 1914 997 498 170 73 44 20 14 3	Scounts [1] 6256 7059 5500 1657 327 58 5 1	counts [1] 6282 7649 5090 1480 289 61 11 1
<pre>6density [1] 0.1766764128 0.1344964770 0.1681445621 0.1926376839 0.1491156593 [6] 0.0917413603 0.0477879500 0.0238700091 0.0081483967 0.0034990174 [11] 0.0021089968 0.0009586349 0.0006710444 0.0001437952</pre>	Sdensity [1] 1.499305e-01 1.691751e-01 1.318123e-01 3.971145e-02 7.836840e-03 1.390021e-03 [7] 1.198294e-04 2.396587e-05	idensity 1] 1.505536e-01 1.833150e-01 1.219863e-01 3.546949e-02 6.926137e-03 1.461918e-01 [7] 2.636246e-04 2.396587e-05
Shoot-PA01-6h	Shoot-PA01-12h	Shoot-PA01-24h
Scounts [1] 3273 2657 3451 4239 3422 1926 1014 524 219 65 37 23 10 3	Scounts [1] 5698 7476 5686 1574 363 59 6 1	Scounts [1] 3035 2611 3477 4334 3452 1972 1108 543 184 73 38 24 10 2
Sdensity [1] 0.1568806020 0.1273546470 0.1654124527 0.2031826679 0.1640224321 [6] 0.0923165412 0.0486027896 0.0251162345 0.0104970522 0.0031155634 [11] 0.0017734746 0.0011024301 0.0004793175 0.0001437952	Sdensity [1] 1,365575e-01 1,791689e-01 1,362700e-01 3,772228e-02 8,699612e-03 1,413986e-03 [7] 1,437952e-04 2,396587e-05	Sdensity [1] 1.454728e-01 1.251498e-01 1.666587e-01 2.077362e-01 1.654604e-01 [6] 9.452140e-02 5.310837e-02 2.602694e-02 8.819441e-03 3.499017e-03 [11] 1.821406e-03 1.150362e-03 4.793175e-04 9.586349e-05

Fig.04



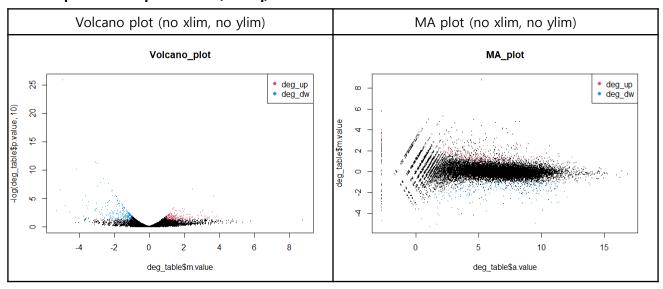
- 같은 group에서 6h와 12h, 12h와 24h, 6h와 24h를 분석한 scatter plot.
- 결과를 분석해보니, 12h와 비교를 하면 그래프가 wide해짐.
- 따라서 12h에서는 6h와 24h와는 별개로 발현되는 gene이 있다고 판단.
- Experiment group에서도 결과는 마찬가지.
- 결과를 분석할때 DEG가 PA01로 인한 DEG차이인지, 시간의 흐름에 따라 다르게 발현되는 DEG인지 구별을 해야함. -> 추가적인 연구 필요.

- No. Total genes : 32833 (TCC 결과 기준)

- No. Selected DEG: 444

Up regulated DEG: 204Down regulated DEG: 240

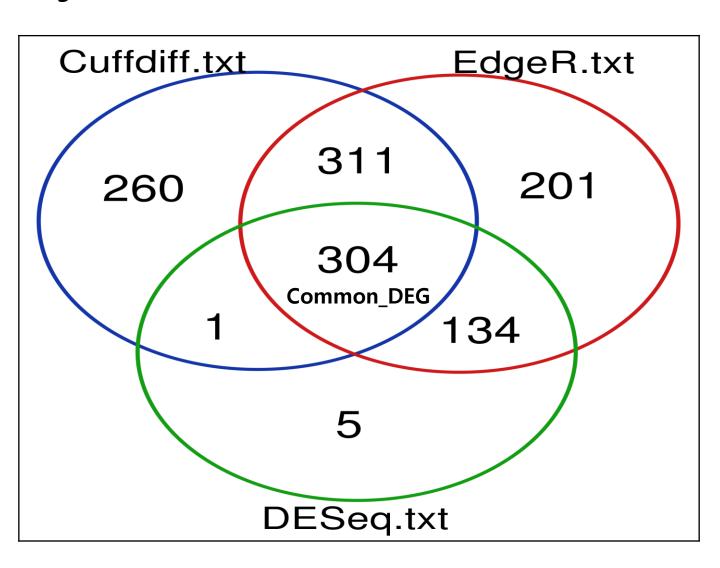
#### Volcano plot & MA plot – TCC(deseq)



- Cuffdiff 외 TCC실행 결과로 인한 volcano plot과 MA plot.
- TCC실행 결과 같은 정보임에도 불구하고, DEG의 개수가 다름
- 또한 UP regulated DEG와 DOWN regulated DEG개수 또한 차이 발생.
- 따라서 연구목적에 따러서 DEG를 알맞게 선별해서 사용해야함.

DEG
Common_DEG

Fig.07



• 연구목적에 따러서 DEG를 알맞게 선별해서 사용해야함.